M1 Informatique -Sorbonne Université

MU4IN801 - MLBDA

Modèles et Langages Bases de Données Avancées

Bernd Amann

COURS 5 - XSCHEMA

Objectifs

Définir un nouveau langage de schémas XML :

- Reprendre les acquis des DTD
- Réutiliser des définitions de structures pour différents éléments
- Exprimer des contraintes plus fortes
- Utiliser XML pour exprimer aussi les schémas

Et aussi

- Prendre en compte les espaces de noms
- Extensibilité
- Notion de clef plus expressive et précise
- Dérivation de types (restriction, extension)

DTD et XML Schema


DTD

DOCUMENT XML

DTD

```
<!ELEMENT note (pour, de, sujet, texte)>
<!ELEMENT pour (#PCDATA)>
<!ELEMENT de (#PCDATA)>
<!ELEMENT sujet (#PCDATA)>
<!ELEMENT texte (#PCDATA)>
```

DTD et grammaires



DTD:

```
<!ELEMENT a (b*cd*) >
<!ELEMENT b EMPTY >
<!ELEMENT c (e*) >
<!ELEMENT d (fq?) >
```

Expression régulières:

- L(b*cd*)={c,bc,cd,bcd, bbc, cdd, bbbc, bbcd, ...}
- $L(e^*)=\{\epsilon, e, ee, ...\}$
- L(fg?)={f,fg}

DTD comme grammaire

Une DTD est un couple (E,R) où

- E est un ensemble de noms d'éléments
- S est un élément de E (racine)
- R={e → r} est un ensemble de règles telles que
 - e ∈ E est un nom d'élément
 - R est une expression régulière sur les noms d'éléments

DTD

```
<!ELEMENT officiel (#PCDATA|cinema|film)*>
<!ELEMENT cinéma (nom, adresse, (séances)*>
```

Grammaire

```
Officiel -> (#PCDATA | cinéma | film)*
Cinéma -> nom adresse (séance)*
```

XML Schema

Un schéma XML est un **document XML** avec un élément racine xs:schema (xs designe l'espace de nom de XML Schema).

XML Schema permet de définir

- · les éléments fils et leur ordre (expressions régulières) TD et
- les attributs
- les valeurs par défaut et les valeurs fixes
- les clefs et références typées
- les types de données des éléments et attributs
- les espaces de noms des balises utilisées et définies

http://www.w3.org/TR/xmlschema-2/

XML Schema

XML Schema

Schéma XML: Types et éléments

```
<?xml version="1.0" ?>
<xs:schema xmlns:xs="http://www.w3.org/2001/XMLSchema"</pre>
          targetNamespace="http://www.w3schools.com"
          xmlns="http://www.w3schools.com"
elementFormDefault="qualified">
<xs:element name="note">
     <xs:complexType>
          <xs:sequence>
               <xs:element name="pour" type="xs:string"/>
               <xs:element name="de" type="xs:string"/>
               <xs:element name="sujet" type="xs:string"/>
               <xs:element name="texte" type="xs:string"/>
          </xs:sequence>
     </xs:complexType>
                                                    <!ELEMENT note (pour,de,sujet,texte)>
</xs:element>
                                                   <!ELEMENT pour (#PCDATA)>
</xs:schema>
                                                   <!ELEMENT de (#PCDATA)>
                                                   <!ELEMENT sujet (#PCDATA)>
                                                    <!ELEMENT texte (#PCDATA)>
```

Déclaration d'Eléments (1)

Un élément a un *modèle de contenu simple ou complexe*

Modèle de contenu simple

- Types simples: string, boolean, float, timeInstant, timePeriod, month, date, ...
- Exemple :

```
<xs:element name="pour" type="xs:string"/>
<xs:element name="datenais" type="xs:date"/>
```

On peut déclarer des valeurs par défaut ou des valeurs fixes :

```
<xs:element name="couleur" type="xs:string" default="bleu"/>
<xs:element name="couleur" type="xs:string" fixed="bleu"/>
```

Déclarations d'Eléments (2)

```
Modèle de contenu complexe : <complexType>
• Types complexes: <sequence>, <choice>, <all>
Contenus mixtes (attribut mixed="true")
<xs:element name="note">
   <xs:complexType>
       <xs:sequence>
           <xs:element name="pour" type="xs:string"</pre>
                        minOccurs="1"
                        maxOccurs="unbounded" />
           <xs:element name="de" type="xs:string"/>
           <xs:element name="sujet" type="xs:string"/>
           <xs:element name="texte" type="xs:string"/>
       </xs:sequence>
   </r></xs:complexType>
</xs:element>
```

Types complexes: sequence, choice, all

```
: séquence ordonnée d'éléments
                                                      : (A,B,C)
<xs:sequence>
                                                      : (A|B|C)
<xs:choice>
                : choix parmi un ensemble d'éléments
<xs:all>
                : séquence non ordonnée
<xs:element name= "ident">
    <xs:complexType>
        <xs:choice>
            <xs:element name="raisonsociale" type="xs:string"/>
            <xs:element name= "identité" type="xs:string"/>
        </xs:choice>
    </xs:complexType>
</xs:element>
```

minoccurs et maxoccurs

	minoccurs	maxoccurs
<xs:sequence></xs:sequence>	Entier >= 0	Entier >= minoccurs
<xs:choice></xs:choice>	Entier >= 0	Entier >= minoccurs
<xs:all></xs:all>	0 ou 1	1

Eléments (3)

Réutilisation de déclarations d'éléments : la déclaration d'un élément peut être référencée dans le contenu d'un autre élément par l'attribut ref.

Déclaration d'Attributs

Déclaration d'un attribut

```
<xs:attribute name="langue" type="xs:string">
```

Les attributs sont typés (toujours des types simples)

Contraintes

- Optionalité : use="optional" | "required" | "prohibited"
- Valeur par défaut : default="string"
- Valeur constante : fixed="10"

Lorsqu'il y a une valeur *fixe* ou une valeur *par défaut*, **use** doit avoir la valeur « optional » (valeur par défaut).

Déclaration d'Attributs

Les atttributs font partie du type de l'élément:

Déclaration de Types

Types simples prédéfinis :

- string
- integer, positiveInteger, negativeInteger,
- Boolean,
- ° time, date,
- ID, IDREF, IDREFS, etc.

Possibilité de définir des **nouveaux types** (*dérivation*)

- ° constructeurs de types complexes: sequence, choice, all
- ° types simples dérivés : contraindre les valeurs (restriction, facettes)
- types complexes dérivées : contraindre la structure (restriction, extension)

Type complexe identifié

MLBDA

Un type peut être identifié par un nom ou anonyme.

Remarque

Une déclaration d'élément peut avoir un attribut type (référence vers un type identifié) ou un élément fils complexType (type anonyme), mais pas les deux simultanément:

Type complexe mixte

Contenu mixte (mélange de texte et d'éléments)

Exemple: <meteo>situation météo pour la <loc>région parisienne</loc>ce mercredi à <heure>13</heure> h : <temps>temps frais et couvert</temps>.</meteo>

Attention: L'ordre des éléments < loc>, < heure>, < temps> doit être respecté.

DTD: <!ELEMENT meteo (#PCDATA|loc|heure|temps) *> ← l'ordre est ignoré

Types dérivés

Notions d'héritage et de spécialisation

Dériver :

- Ajouter ou contraindre des caractéristiques d'un type
- Définition d'un nouveau type résultant

Dérivation par *restriction*

- Réduction du champ de portée d'un type
- Ajouter des contraintes (facettes, maxOccurs, minOccurs, ...)

Dérivation par extension

- Réutilisation d'un type complexe
- Ajouter des informations supplémentaires (attribut, élément)

Extension et restriction de types simples

Contraintes de types simples

Les *facettes* permettent de définir un nouveau type simple à partir d'un type simple existant (appelé le type de base), en spécifiant des valeurs pour une ou plusieurs facettes.

Exemple: le type **xs:string** a six *facettes optionnelles* :

- length, minLength, maxLength
- pattern : expression régulière définissant la suite de caractères acceptable
- enumeration : liste de valeurs acceptables
- whitespace : traitements des espaces blancs (tab, espace, retour chariot)

Facettes xs:length

```
<xs:simpleType name="TelephoneNumber">
  <xs:restriction base="xs:string">
      <xs:length value="8"/>
   <xs:pattern value="\d{3}-\d{4}"/>
  </xs:restriction>
</xs:simpleType>
Type derivé de xs:string appelé TelephoneNumber;
Les éléments de ce type ont des valeurs de type string ;
La longueur de la chaîne de caractère doit être exactement 8 ;
La chaîne doit respecter le format ddd-dddd (où d est un chiffre)
```

Facettes xs:enumeration

```
<xs:simpleType name="forme">
    <xs:restriction base="xs:string">
        <xs:enumeration value="cercle"/>
        <xs:enumeration value="triangle"/>
        <xs:enumeration value="carré"/>
        <xs:enumeration value="carré"/>
        </xs:restriction>
</xs:simpleType>
```

Un élément de type forme doit avoir comme valeur « cercle », « triangle » ou « carré ».

Facettes xs:length et xs:pattern

```
<xs:complexType name="typeSociete">
    <xs:sequence>
           <xs:element name="siret">
          <xs:simpleType>
            <xs:restriction base="xs:string">
                 <xs:length value="16">
                 <xs:pattern value="\d(6)\s\d(3)\s\d(5)"/>
            </xs:restriction>
          </xs:simpleType>
        </xs:element>
    </xs:sequence>
</xs:complexType>
<xs:element name="societe" type="typeSociete"/>
```

Facettes pour xs:integer

```
<xs:simpleType name= "Temperature">
    <xs:restriction base="xs:integer">
        <xs:minInclusive value="-60"/> 8 f
        <xs:maxInclusive value="80"/>
        </xs:restriction>
    </xs:simpleType>
```

8 facettes pour xs:integer:

- totalDigitspattern
- whitespace
- enumeration
- maxInclusive, minInclusive
- maxExclusive, minExclusive.

Utilisation de plusieurs facettes

- Les facettes (contraintes) **pattern** et **enumeration** sont *disjonctives* (au moins une doit être vérifiée)
- Toutes les **autres facettes** (contraintes) sont *conjonctives* (toutes doivent vérifiées)

La forme doit être un cercle, un triangle **OU** un carré.

Le numéro de téléphone doit avoir 8 chiffres, **ET** doit respecter la forme suivante ddd-dddd.

```
<xs:simpleType name="forme">
  <xs:restriction base="xs:string">
        <xs:enumeration value="cercle"/>
        <xs:enumeration value="triangle"/>
        <xs:enumeration value="carre"/>
        <xs:enumeration value="carre"/>
        </xs:restriction>
</xs:simpleType>
```

MLBDA

```
<xs:simpleType name="TelephoneNumber">
  <xs:restriction base="xs:string">
        <xs:length value="8"/>
        <xs:pattern value="\d{3}-\d{4}"/>
        </xs:restriction>
</xs:simpleType>
```

Facettes de facettes

TEMPERATURES

```
<xs:simpleType
    name= "Temperature">
    <xs:restriction base="xs:integer">
     <xs:minInclusive value="-60"/>
     <xs:maxInclusive value="80"/>
     </xs:restriction>
</xs:simpleType>
```

TEMPERATURES EN FRANCE

```
<xs:simpleType
    name= "TemperatureEnFrance">
    <xs:restriction base= "Temperature">
        <xs:minInclusive value="-30"/>
        <xs:maxInclusive value="45"/>
        </xs:restriction>
</xs:simpleType>
```

Types d'attributs : xs:enumeration

Un attribut peut être restreint à un ensemble de valeurs de type simple:

Extension et restriction de types complexes


Restriction de types complexes

L'élément **xs:complexContent** permet d'étendre ou de restreindre un type complexe. <xs:complexType name="Publication"> <xs:sequence> **Publication** <xs:element name="Titre" type="xs:string" maxOccurs="unbounded"/> <xs:element name="Auteur" type="xs:string" maxOccurs="unbounded"/> Titre* </xs:sequence> Auteur* </xs:complexType> <xs:complexType name= "PublicationUniqueAuteur"> <xs:complexContent> restriction <xs:restriction base="Publication"> <xs:sequence> <xs:element name="Titre" type="xs:string" maxOccurs="unbounded"/> <xs:element name="Auteur" type="xs:string" maxOccurs="1" /> Publication Unique Auteur </xs:sequence> </xs:restriction> On répète les éléments du type de Titre* </xs:complexContent> base qu'on veut garder (Titre). Auteur </xs:complexType>

Extension de types complexes

```
<xs:complexType name="personneType">
  <xs:sequence>
  <xs:element name="nom" type="xs:string"/>
  <xs:element name="datenais" type="xs:date"/>
  </xs:sequence>
</xs:complexType>
<xs:complexType name="etudiantType">
 <xs:complexContent>
  <xs:extension base="personneType">
    <xs:sequence>
     <xs:element name="cursus" type="xs:string"/>
    </xs:sequence>
  </xs:extension>
                            On ne répète pas les éléments
  </xs:complexContent>
                            du type de base qu'on veut
</xs:complexType>
```

garder.



Types complexes et leur contenu

Types de *contenu* de types complexes :

- simples : nœuds texte ou vide
- complexes : nœuds attributs et nœuds éléments

Eléments à contenu vide (ne contenant que des attributs) :

```
<xs:element name="book">
  <xs:complexType>
     <xs:attribute name="isbn" type="isbnType"/>
  </xs:complexType>
```

L'élément <book> est de **type complexe** avec un **contenu simple** (vide):

```
<book isbn="0123456789" />
```

</xs:element>

xs:simpleContent vs. xs:complexContent

- <xs:simpleContent> permet de définir des nouveaux types complexes par extension ou restriction d'un type simple.
- <xs:complexContent> permet de définir des nouveaux types complexes par extension ou restriction d'un type complexe.

X est un type complexe

Y est un type simple

xs:simpleContent

Pour définir un élément ne contenant que du texte et des attributs, on dérive un type complexe avec un type de contenu simple (ici une extension du type string avec un attribut) en utilisant l'élément xs:simpleContent :

Clés et références

Clés et références

Dans les DTD:

- un élément ayant un attribut de type IDREF doit référencer un élément ayant un attribut de type ID.
- Le parser vérifie que la valeur de IDREF correspond à une valeur existante de ID.
- On ne peut pas définir des références « typés » : les attributs de type IDREF peuvent références tous les éléments avec un attribut ID

Dans XML Schema:

MLBDA

- une clé est un élément <xs:key> qui définit les identifiants pour un ensemble d'éléments
- une références est un élément <xs:keyref> qui définit les éléments qui correspondent aux références vers une clé.
- On peut « typer » les références: les éléments A sont des références vers les éléments B

Unicité et clés

Xschema permet de définir l'unicité avec <xs:unique> et <xs:key>.

Key: un élément ou un attribut (ou une combinaison des deux) défini avec <xs:key> :

- doit toujours être présent (minOccurs > 0)
- ne peut pas avoir une valeur nulle (nillable="false")
- ° doit être unique

Unique:

o identique à **key** sauf que seule l'unicité est requise (pas l'existence).

Key implique unique, mais unique n'implique pas key

Utilisation

L'élément **<xs:key>** doit être imbriqué dans un élément, et doit se trouver après le modèle de contenu et les déclarations d'attributs.

L'élément **<xs:selector>** est utilisé comme un *fils de* <*xs:key>* pour *déterminer l'ensemble d'éléments auxquels la clé s'applique*.

L'élément **<xs:field>** est utilisé comme un *fils de <xs:key>* pour *determiner l'élément ou l'attribut clé*.

Attention: Il peut y avoir plusieurs éléments <xs:field>.

Exemple : définition de clés

```
<xs:element name="librairie">
                                                Livres identifiés par ISBN
    <xs:complexType>
         <xs:sequence>
           <xs:element name="Livre" maxOccurs="unbounded">
                  <xs:complexType>
                      <xs:sequence>
                           <xs:element name="Titre" type="xs:string"/>
                           <xs:element name="Auteur" type="xs:string"/>
                           <xs:element name="ISBN" type="xs:string"/>
                      </xs:sequence>
                 </xs:complexType>
                                          .... <xs:key name="Lclef">
          </xs:element>
                                                  <xs:selector xpath="Livre"/>
         </xs:sequence>
                                                  <xs:field xpath="ISBN"/>
    </xs:complexType> ....
                                             </xs:key>
                                         </xs:element>
```

Exemple : définition de clés

```
<xs:element name="Librairie">
    <xs:complexType>
        <xs:sequence>
                                     Livres identifiés par le couple (Titre, Auteur)
        <xs:element name="Livre"</pre>
maxOccurs="unbounded">
        <xs:complexType>
        <xs:sequence>
        <xs:element name="Titre" type="xs:string"/>
        <xs:element name="Auteur" type="xs:string"/>
        <xs:element name="ISBN" type="xs:string"/>
                </xs:sequence>
                                           .. suite:
        </xs:complexType>
                                               <xs:key name="Lclef">
        </xs:element>
                                                    <xs:selector xpath="Livre"/>
        </xs:sequence>
                                                    <xs:field xpath="Titre"/>
    </xs:complexType> ...
                                                    <xs:field xpath="Auteur"/>
                                               </xs:key>
                                           </xs:element>
```

Exemple : clés et références

```
<Librairie>
  <LesLivres>
     <Livre>
        <Titre>Le soleil des Scorta</Titre>
        <Auteur>Laurent Gaudé</Auteur>
        <Date>2004</Date>
        <ISBN>0-123-45678-9</ISBN>
  </Livre>
  </LesLivres>
  <Signatures>
     <Auteur>
        <Nom>Laurent Gaudé</Nom>
        <LivreAsigner>
  <ISBNRef>0-123-45678-9</ISBNRef>
      </LivreAsigner>
     </Auteur>
  </Signatures>
</Librairie>
```

<xs:keyref> doit avoir autant d'éléments
<field> que <xs:key>, ils doivent être dans le même ordre, et doivent avoir les mêmes types.

Unicité: <unique>

L'élément **<xs:unique>** se définit de façon analogue à l'élément <xs:key> avec un élément fils <xs:selector> et un ou plusieurs éléments fils <xs:field>.

La seule différence est que l'existence de l'élément désigné par <xs:field> n'est pas obligatoire.

Tous les éléments ISBN ont une valeur unique, mais un élément livre peut ne pas avoir de valeur pour ISBN.

Espaces de noms

Utilisation des schémas

Espaces de noms

Importer, dans un document, des éléments ou des attributs contenus dans des entités externes, peut entraîner des conflits de noms.

Pour éviter ces conflits, on définit des espaces de noms

L'objectif est de pouvoir mélanger plusieurs vocabulaires au sein d'un même document.

Un espace de nom permet

- o d'identifier la provenance de chaque élément et attribut,
- o d'éviter les conflits de noms,
- ° de faire coopérer les noms des différentes structures XML : copiercoller des fragments de documents
- de réutiliser des déclarations

Espace de noms (NameSpace)

Un espace de noms XML est une collection abstraite de noms d'éléments ou de noms d'attributs identifié par une URI

Exemples:

- XMLSchema: http://www.w3.org/2001/XMLSchema
- Dublin Core : http://purl.org/dc/elements/1.1/
- XSLT: http://www.w3.org/999:XSL.Format
- MathML: http://www.w3.org/1998:Math/MathML

Un élément ou attribute A d'un espace de nom N est désigné par un nom qualifié N:A compose de l'URI de l'espace de nom et du nom local

Exemples:

- http://www.w3.org/2001/XMLSchema:element
- http://purl.org/dc/elements/1.1/auhor

Au lieu d'utiliser les URI on peut associer des préfixes aux espace de nom :

° Un préfixes est déclaré comme attribut d'un élément et sa définition porte sur l'élément et son le sous-arbre.

Déclaration de l'espace de nom

<xs:schema xmlns:xs=http://www.w3.org/2001/XMLSchema targetNamespace="http://www.w3schools.com" xmlns="http://www.w3schools.com"</pre>

elementFormDefault="qualified">

- xmlns:xs="http://www.w3.org/2001/XMLSchema" indique l'espace de noms contenant les éléments et types de données utilisés dans le schéma (schema, element, sequence, complexType, string, etc.).
- targetNamespace="http://www.w3schools.com" indique l'espace de noms pour les éléments définis par ce schéma (note, de, pour, sujet, texte).

Attributs xs:schema

xmlns="http://www.w3schools.com"

 indique l'espace de noms par défaut (le même que le targetNamespace). Utilisé lors de références (attribut ref) lorsqu'on ne précise pas l'espace de noms.

elementFormDefault="qualified"|"unqualified"

- ° « qualified » : tous les éléments sont dans l'espace de noms cible.
- ° « unqualified » : seuls les éléments définis globalement (dans un élément directement fils de l'élément xs:schema) sont dans l'espace de noms cible. Les autres sont sans espace de noms.

Référencer un schéma

- Dans la racine du document XML à valider, on utilise l'attribut schemaLocation, qui indique l'espace de noms cible et l'adresse du schéma.
- L'attribut **schemaLocation** se trouve dans l'espace de noms des instances de schémas
- La valeur de schemaLocation est une suite d'URI séparés par des espaces.
- Les URI vont par paires 'nsN schN' où nsN est l'espace de nom cible du schéma schN.
- schemaLocation='ns1 sch1 ns2 sch2 ... nsN schN'

Exemple

Fichier base.xml

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<base
    xmlns="http://www.w3schools.com"
    xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
    xsi:schemaLocation="Espace_TPXML base.xsd">
    ....
```

Conclusion

XML Schema et grammaires d'arbre

Une grammaire d'arbre est un triplet (T,E,S,P) où

- E est un ensemble de noms d'éléments (terminaux)
- T est un ensemble de noms de types (non-terminaux)
- S est un sous-ensemble de E
- $R = \{t \rightarrow e r\}$ est un ensemble de règles telles que
 - $t \in T$ est un nom de type
 - $e \in E$ est un nom d'élément
 - r est une expression régulières sur les noms de types

DTD

- «!ELEMENT officiel (#PCDATA | cinéma | film)*>
- <!ELEMENT cinéma (nom, adresse, (séance)*)>

Grammaire d'arbres

- T={TOffi, TCine, TFilm, TNom, TAdresse, TSéance, PCdata}
- E={officiel, cinéma, film, nom, adresse, séance}
- S={T}

```
Règles P:
```

```
TOffi ⇒ officiel (TCine | TFilm | Pcdata)*

TCine ⇒ cinema (TNom, TAdresse, TSéance*),

TFilm ⇒ film (Titre, Pays, Realisateur, Acteurs*),

TNom ⇒ nom (Pddata), ... }
```

DTD: une seule règle par élément

XMLSchema: Grammaires à types uniques

Types concurrents:

 Deux types différents A et B sont concurrents entre eux s'il existe deux règles de production A ⇒ c r et B ⇒ c r' pour le même élément c.

XMLSchema est une grammaire d'arbres à types uniques

- les symboles dans S ne sont pas concurrents et,
- pour chaque règle de production, les non-terminaux dans son modèle de contenu ne sont pas concurrents.

Validation simple:

- Dans une grammaire à types uniques il est possible d'identifier le type d'un
 - élément à partir de son nom et du type de son parent.

Conclusion: DTD et XML Schéma

DTD : grammaire d'arbre locale (chaque élément à un seul type)

XML Schema: grammaire d'arbre à type unique

- Plus expressif que DTD
- Validation reste simple

Il existe d'autres langages de typage XML :

Relax NG, CDuce, etc.

Tous ces langages sont formellement fondés sur les grammaires/automates d'arbres.